

基于 Monte Carlo 模拟的 idopNetwork、WGCNA 与 GENIE3 性能评估 (Lotka-Volterra 场景)

1. 方法

1.1 模拟数据生成

1.1.1 真实网络构建

采用单一稀疏有向交互矩阵 **B** (10×10 物种) 作为所有重复的真实网络:

- 非对角元素以 25% 概率非零 (稀疏度 = 0.25) , 权重在 $[-0.5, 0.5]$ 上均匀采样
- 对角元素 (自调控) 为负值, 取值范围 $[-0.5, -0.1]$, 保证 LV 系统的局部稳定性
- 由固定随机种子 (seed = 42) 生成, 确保可重复性
- 实际真实边数: **22 条** (稀疏度 24.4%)

1.1.2 Lotka-Volterra ODE 模拟

物种丰度轨迹由广义多物种 Lotka-Volterra 方程生成:

$$\frac{dx_i}{dt} = r_i x_i + \sum_j B_{ij} x_i x_j, \quad i = 1, \dots, S$$

其中 $r_i \sim \text{Uniform}(0.1, 0.5)$ (正增长率) , 初值 $x_i(0) \sim \text{Uniform}(0.5, 2.0)$, 使用 `deSolve::lsoda` 数值求解。在 30 个等间隔时间点 (梯度位置) 上采样, 再在对数尺度叠加加性高斯噪声 ($\sigma = 0.05$) 模拟测量误差。

1.1.3 主实验参数

参数	值
物种数 S	10
梯度位置数	30
Monte Carlo 重复次数	30
噪声标准差 (对数尺度)	0.05
随机种子	42

1.2 网络推断方法

1.2.1 idopNetwork

核心思想：将物种动态描述为准动态 LV-ODE，将丰度数据随梯度的变化视为连续时间轨迹。通过幂函数拟合（power_equation_fit）将梯度位置转化为 Habitat Index，再对每个物种独立执行自适应 LASSO 变量选择（get_interaction）和 ODE 参数优化（qdODE_all），最终通过 network_conversion 输出边的方向、权重和符号。

输出类型：有向 × 有权重 × 有符号 网络

1.2.2 WGCNA

核心思想：基于皮尔逊相关矩阵，通过软阈值幂函数（β）将相关矩阵转化为邻接矩阵，再计算拓扑重叠测度（TOM）作为边权重。自动选择使网络近似无标度的最优软阈值。

输出类型：无向 × 有权重 × 无符号/无方向 网络

1.2.3 GENIE3

核心思想：将每个物种的丰度视为因变量，其余物种丰度视为自变量，拟合随机森林回归模型，以变量重要性作为调控强度的代理指标。每个目标物种独立训练（1000 棵决策树），权重矩阵经转置得到最终得分。

输出类型：有向 × 有权重 × 无符号 网络

1.3 得分矩阵约定

三种方法统一输出 $S[\text{regulator}, \text{target}]$ （调控者行，目标列），与真实网络约定一致：
 $B[\text{target}, \text{regulator}] \neq 0$ 表示存在 $\text{regulator} \rightarrow \text{target}$ 的边。

1.4 评估指标

1.4.1 边存在检测

对所有有序物种对 $(i \rightarrow j, i \neq j)$ ，共 $S \times (S - 1) = 90$ 个候选有向边：

- **AUROC：**ROC 曲线下面积，随机基准 = 0.5
- **AUPRC：**精确率-召回率曲线下面积，随机基准 ≈ 0.244 （正样本率 24.4%）

1.4.2 Top-k 阈值下的 MCC

将预测得分前 k ($k = \text{真实边数 } 22$) 的候选边标记为正例，计算 **MCC**（Matthews 相关系数）：范围 $[-1, 1]$ ，随机基准 ≈ 0 。该指标在固定阈值下综合衡量精准率与召回率的平衡，比 AUROC 对边预测的实用质量更敏感。

1.4.3 方向与符号准确率

- **方向准确率** (`dir_acc`) : 对真实边 $i \rightarrow j$, 若 $S[i, j] > S[j, i]$ 则预测正确, 随机基准 = 0.5
- **符号准确率** (`sign_acc` , 仅 idopNetwork) : 预测符号与真实符号一致的比例, 随机基准 = 0.5

1.5 参数敏感性扫描

为评估方法性能对关键参数的稳健性, 在 LV 场景下额外执行两条扫描线, 每个参数值运行 20 次 Monte Carlo 重复:

- **噪声方差扫描**: $\text{NOISE_SD} \in \{0.01, 0.03, 0.05, 0.07, 0.10\}$, 固定 $\text{N_POSITIONS} = 30$
- **样本量扫描**: $\text{N_POSITIONS} \in \{15, 20, 30, 50, 80\}$, 固定 $\text{NOISE_SD} = 0.05$

结果以均值 $\pm$ 95% CI 展示 (`fig_sensitivity`) 。

2. 结果

2.1 边存在检测能力

表 1. LV 场景主实验结果 (30 次重复, 均值 $\pm$ 标准差)

方法	AUROC	AUPRC	MCC
idopNetwork	0.734 $\pm$ 0.063	0.397 $\pm$ 0.075	0.266 $\pm$ 0.131
GENIE3	0.633 $\pm$ 0.053	0.332 $\pm$ 0.056	0.114 $\pm$ 0.092
WGCNA	0.477 $\pm$ 0.038	0.279 $\pm$ 0.041	0.049 $\pm$ 0.073

随机基准: $\text{AUROC} = 0.5$, $\text{AUPRC} \approx 0.244$, $\text{MCC} \approx 0$

主要发现:

1. idopNetwork 的 AUROC (0.734) 高于 GENIE3 (0.633) 约 10 个百分点, 高于 WGCNA (0.477) 约 26 个百分点。
2. MCC 差距更为突出: idopNetwork (0.266) 是 GENIE3 (0.114) 的 2.3 倍、WGCNA (0.049) 的 5.4 倍, 反映在 top- k 边选择上 idopNetwork 的精准度优势。

2.2 方向准确率与符号准确率

表 2. 方向与符号推断能力 (LV 场景, 30 次重复)

方法 方向准确率 备注 ----- ----- ----- -----	idopNetwork 0.718 ± 0.094 有向有符号
GENIE3 0.533 ± 0.094 有向无符号	WGCNA — 无向，不适用

随机基准: 方向准确率 = 0.5, 符号准确率 = 0.5

主要发现:

idopNetwork 方向准确率为 71.8%，比随机基准高 21.8 个百分点，说明 ODE 拟合确实从丰度轨迹中提取了有效的方向信息。GENIE3 方向准确率 (53.3%) 略优于随机，但提升有限 (+3.3 个百分点)。

2.3 参数敏感性分析

fig_sensitivity 展示了 AUROC 和 MCC 随噪声标准差 (左列) 和样本量 (右列) 变化的趋势 (均值 ± 95% CI, 每点 20 次重复)。

噪声方差扫描 ($\text{NOISE_SD} \in \{0.01, 0.03, 0.05, 0.07, 0.10\}$) :

- 三种方法的 AUROC 和 MCC 均随噪声增大而下降，但 idopNetwork 在全部噪声范围内始终保持最高的边检测性能，其优势在低噪声 (0.01–0.03) 条件下最为显著。

样本量扫描 ($\text{N_POSITIONS} \in \{15, 20, 30, 50, 80\}$) :

- idopNetwork 和 GENIE3 的性能均随样本量增大而提升，但 idopNetwork 在全部样本范围内始终保持最高的边检测性能

3. 讨论

3.1 idopNetwork 的信息优势

与 WGCNA 和 GENIE3 相比，idopNetwork 在以下三个维度提供了本质性的信息增益:

3.1.1 有向网络

WGCNA 基于相关性，输出对称邻接矩阵，天然无法区分 A 影响 B 还是 B 影响 A。GENIE3 通过随机森林的变量重要性引入不对称性，在 LV 场景中方向准确率 (53.3%) 略优于随机，改善有限。idopNetwork 的有向性来自 ODE 的因果结构：若物种 j 调控物种 i ，则参数 B_{ij} 在 i 的方程中出现，反向 B_{ji} 不影响 i 的动态（除非存在反向调控）。这种基于机制的方向性使方向准确率达到 71.8%，比 GENIE3 高 18.5 个百分点。

生态学意义：有向网络可区分捕食者与猎物、竞争中的优势方与劣势方，对理解群落调控机制和预测扰动效应至关重要。

3.1.2 有权重网络

三种方法均输出有权重的网络，但权重含义不同：WGCNA 的 TOM 反映相关性拓扑邻近度，物理意义抽象；GENIE3 的变量重要性为无量纲相对量；idopNetwork 的 ODE 参数 B_{ij} 直接对应广义 LV 方程中的互作系数，具有明确的生态学量纲，可直接用于数值模拟和稳定性分析。在 top- k 阈值下 MCC (0.266 vs 0.114) , idopNetwork 的权重排序能力更为精准。

3.1.3 Top-k MCC 的评估前提与实际含义

MCC 基于 top-k 阈值计算，其中 $k = 22$ 取自真实边数。这是模拟评估的特有条件——研究者在已知网络结构时才能使用最优 k 。在实际应用中，真实边数未知，各方法需通过置换检验、交叉验证或稀疏性先验等方式自行确定截断阈值，MCC 值普遍低于模拟结果中的数字。

因此，MCC 数值并非 GENIE3 或任何方法的算法本身"使用"了 $k = 22$ 这一先验信息—— k 仅用于事后评估，对方法的推断过程没有影响。然而，如果 GENIE3 在实际应用中选择了次优截断阈值，其 MCC 可能明显低于表 1 的 0.114。相比之下，idopNetwork 无需知道先验参数 k 就可能达到更好的效果。

3.1.4 有符号网络

这是 idopNetwork 相较于其他两种方法最独特的能力。WGCNA 和 GENIE3 均无法区分正调控（促进）与负调控（抑制）：

$$B_{ij} > 0 \Rightarrow \text{物种 } j \text{ 促进物种 } i \quad B_{ij} < 0 \Rightarrow \text{物种 } j \text{ 抑制物种 } i$$

生态学意义：符号网络可直接构建物种互作类型矩阵（竞争、互惠共生、捕食等），是评估群落稳定性（May 稳定性判据）和预测物种灭绝风险的必要输入。